

Informe Final — Proyecto Integrador

Analisis de usuarios de una plataforma de streaming | Minería de Datos 1 | 2025

Integrantes: Taboada Emiliano Nicolas | Perez Carletti Martin

1. CONTEXTO Y OBJETIVO

Este proyecto construye un pipeline de analisis reproducible sobre un dataset de usuarios de una plataforma de streaming. El objetivo es aplicar los contenidos de Minería de Datos 1 para construir un proyecto de analisis de datos con decisiones justificadas, trazabilidad del proceso y comunicacion clara de los resultados. El alcance incluye inspeccion inicial, limpieza, EDA, escalamiento y PCA; no es un proyecto de modelado predictivo.

2. DATASET Y CALIDAD INICIAL

El dataset original contenia **8.160 registros y 8 variables**: *user_id*, *age*, *subscription_plan*, *monthly_watch_time_mins*, *country*, *favorite_genre*, *last_login_date* y *customer_support_tickets*. La inspeccion inicial identifico:

- Valores nulos en tres columnas: *monthly_watch_time_mins* (193), *favorite_genre* (240) y *last_login_date* (384).
- Tipo de dato incorrecto en *last_login_date* (cargada como object en lugar de fecha).
- Valores imposibles en *age* (negativos y superiores a 120) y *monthly_watch_time_mins* (negativos y mayores a 43.200).
- Variantes inconsistentes en categorias: Estandar / estandar / Std, Brasil / Brazil / brasil, Accion / ACCION / Action.
- Tres formatos de fecha mezclados en *last_login_date* (YYYY-MM-DD, MM-DD-YYYY, YYYY/MM/DD).

3. DECISIONES DE LIMPIEZA Y PREPARACION

Variables categoricas

Se unificaron variantes inconsistentes en *subscription_plan*, *country* y *favorite_genre* bajo una forma canonica en minusculas sin tildes. Los nulos en *favorite_genre*, donde no era posible determinar si el dato era no registrado o indefinido, se etiquetaron como *sin_definir* en lugar de imputar o eliminar el registro.

Fechas (*last_login_date*)

Se forzo la conversion al tipo fecha con `errors='coerce'`, convirtiendo formatos invalidos a NaT. Se eliminaron registros con fecha futura (imposibles en contexto real) y los nulos restantes (no existe criterio valido para imputar una fecha de ultimo acceso). Se derivio la variable *days_since_last_login* para mayor utilidad analitica.

Edad (*age*)

Se eliminaron registros con edad igual a 0 o superior a 120, ambos imposibles para usuarios reales. No existe criterio valido para imputar la edad de un usuario desconocido.

Minutos de visualizacion

Se eliminaron valores negativos (fisicamente imposibles) y valores superiores a 43.200 minutos (limite absoluto de un mes). Los nulos restantes se imputaron con la mediana agrupada por *subscription_plan*, ya que el comportamiento de visualizacion varia razonablemente segun el plan. Outliers altos pero dentro del rango posible (~4.000 min/mes) se conservaron.

Tickets de soporte

Se elimino un registro con valor negativo (imposible). El valor maximo de 99 tickets fue conservado y documentado como observacion de interes analitico.

Etapas	Filas	Variables
Dataset original	8.160	8
Tras limpieza y preparacion	7.067	9
Registros eliminados	1.093 (13,4 %)	—

Variable derivada incorporada: *days_since_last_login*. Dataset original preservado intacto en *data/raw/*. Cada transformacion registrada en *logs/pipeline_log.csv*.

4. HALLAZGOS DEL ANALISIS EXPLORATORIO

Distribucion de edad

La base de usuarios es predominantemente adulta joven. La mayor concentracion se encuentra entre los 26 y 35 anos, con distribucion relativamente uniforme entre 18 y 60 anos y muy pocos usuarios en los extremos.

Plan de suscripcion predominante

El plan basico es el mas frecuente, representando aproximadamente el 44 % de la base. Este segmento es el punto de referencia natural para comparaciones entre planes.

Consumo segun plan

El consumo mensual de minutos crece de forma consistente de basico a estandar y de estandar a premium. Los usuarios premium presentan una mediana claramente superior, lo que sugiere que el plan contratado se refleja en el uso real de la plataforma. Sin embargo, la dispersion dentro de cada plan es considerable.

Tickets y dias sin ingresar

La correlacion de Pearson entre `customer_support_tickets` y `days_since_last_login` fue de 0,004, practicamente nula. La hipotesis de que una experiencia tecnica negativa se asocia con el abandono de la plataforma no encuentra respaldo en los datos disponibles.

Correlacion entre variables numericas

La matriz de correlacion mostro coeficientes cercanos a cero entre todas las variables numericas. Las cuatro variables describen dimensiones independientes del comportamiento del usuario.

5. REDUCCION DE DIMENSIONALIDAD — PCA

Se seleccionaron las cuatro variables numericas del dataset: `age`, `monthly_watch_time_mins`, `customer_support_tickets` y `days_since_last_login`. Se aplico `StandardScaler` antes del PCA para igualar la escala de todas las variables y evitar que `monthly_watch_time_mins` (valores en miles) dominara el analisis sobre `customer_support_tickets` (valores menores a 5).

Componente	Varianza explicada	Varianza acumulada
PC1	25,4 %	25,4 %
PC2	25,2 %	50,6 %
PC3	24,8 %	75,4 %
PC4	24,6 %	100,0 %

Las cuatro componentes explican proporciones casi identicas de varianza, sin ningun codo visible en el scree plot. Esto confirma que las variables no estan correlacionadas y que PCA no permite una reduccion de dimensionalidad sin perdida significativa. Retener 2 componentes implicaria conservar solo el 50,6 % de la informacion original.

PC1 puede interpretarse como una dimension de actividad e involucramiento: valores bajos corresponden a usuarios jovenes con mayor consumo, valores altos a usuarios con mas tickets y mayor tiempo sin ingresar. **PC2** captura principalmente la oposicion entre edad y tickets contra el consumo mensual. El resultado mas relevante del PCA no es la reduccion en si, sino la confirmacion de que las cuatro variables aportan informacion independiente y complementaria.

6. CONCLUSIONES Y LIMITACIONES

El analisis describio una base de usuarios predominantemente adulta joven, con el plan basico como segmento dominante. Se verifico que el plan contratado se refleja en el uso real de la plataforma, aunque la dispersion interna de cada plan es considerable. No se encontro asociacion entre tickets de soporte y dias sin ingresar. Las cuatro variables numericas describen aspectos independientes del comportamiento del usuario.

Limitaciones:

- El dataset no incluye informacion sobre el contenido consumido, por lo que no es posible contrastar la preferencia declarada en `favorite_genre` con el consumo real.
- La variable `favorite_genre` presenta un 3 % de registros etiquetados como `sin_definir` por ambigüedad en el dato original.
- La ausencia de una variable temporal de fecha de registro impide analizar la evolucion del comportamiento a lo largo del tiempo.
- Las correlaciones nulas entre variables limitan la capacidad de PCA para resumir el dataset de forma compacta.

7. ENLACES

Repositorio GitHub: https://github.com/emitab/PI_Mineria_Datos_1

Aplicacion Streamlit: (enlace publico disponible en el README del repositorio)

Log ETL: `logs/pipeline_log.csv` | Notebooks: `notebooks/` | Informe: `reports/informe_final.pdf`